

FORMULA 1

Machine Learning Project

Analyse, Modélisation & Prédictions F1 2026

Étudiant	Bounhar ElMahjoub
N° Apogée	2330686
Filière	ISI — Semestre 6
Cours	Machine Learning — Prof. Fahd Kalloubi
Dataset	Formula 1 Complete History 1950–2026 (Kaggle)
Fichier utilisé	results.csv — 25 939 entrées, 15 colonnes
Année académique	2025 – 2026

1. Introduction

La Formule 1 est l'une des disciplines sportives les plus riches en données : chaque Grand Prix génère des milliers de points de mesure sur les performances des pilotes, des écuries, et des stratégies de course. Ce projet applique les techniques de Machine Learning vues en cours pour extraire des connaissances de ces données historiques et produire des prédictions concrètes sur la saison 2026.

Trois problèmes ML distincts sont traités :

- Problème 1 — Classification : prédire si un pilote va gagner la course (is_winner binaire)
- Problème 2 — Régression : prédire la position finale exacte de chaque pilote (1 à ~20)
- Problème 3 — Clustering : découvrir des archétypes naturels de pilotes sans labels prédéfinis

L'ensemble du projet repose sur un seul fichier CSV (results.csv) couvrant les saisons 1950 à 2026, soit 25 939 entrées de résultats de course.

2. Dataset & Structure des Données

2.1 Source

Source : Kaggle — Formula 1 Complete History 1950–2026

Fichier utilisé : results.csv

2.2 Colonnes du fichier results.csv

Colonne	Type	Description
season	Integer	Saison (1950–2026)
round	Integer	Numéro de la manche dans la saison
race_name	String	Nom du Grand Prix
driver_id	String	Identifiant unique du pilote
driver_name	String	Nom complet du pilote
constructor_id	String	Identifiant de l'écurie
constructor	String	Nom de l'écurie
grid	Integer	Position de départ sur la grille
position	Integer	Position finale dans la course
points	Float	Points marqués lors de la course
laps	Integer	Nombre de tours complétés
status	String	Statut final (Finished, DNF, +N Laps...)
time	String	Temps de course ou écart avec le leader
fastest_lap	String	Temps du meilleur tour en course
fastest_lap_rank	Float	Rang du meilleur tour parmi tous les pilotes

2.3 Traitement des valeurs manquantes

Les valeurs manquantes sont encodées comme 'N' dans le CSV Kaggle. Elles sont remplacées par NaN au chargement, puis les lignes sans position finale ou position de départ sont supprimées. Les colonnes numériques sont converties via `pd.to_numeric` avec `errors='coerce'`.

2.4 Auto-détection des colonnes

Le dataset Kaggle existe en deux versions (ancienne : `positionOrder`, nouvelle : `position`). Le notebook détecte automatiquement la version disponible via des variables `POS_COL`, `RANK_COL`, `STATUS_COL` — garantissant la compatibilité quelle que soit la version téléchargée.

3. Exploration des Données (EDA)

3.1 Statistiques générales

Indicateur	Valeur
Entrées totales	25 939
Courses (Grands Prix)	1 100+
Pilotes uniques	870+
Constructeurs	210+
Saisons couvertes	1950 – 2026
Courses 2026 disponibles	3 (Australie, Chine, Japon)

3.2 Observations clés

- La position de départ (grid) est fortement corrélée à la position finale — c'est le prédicteur individuel le plus puissant.
- Les classes sont très déséquilibrées pour le problème de classification : ~5% de gagnants seulement. On privilégie donc AUC-ROC et F1 plutôt que l'accuracy.
- Le statut 'Finished' est le plus fréquent, mais les DNF (abandons) représentent une proportion significative et constituent une feature informative.
- Le nombre de courses par saison a augmenté de 7 (1950) à 24 (2024–2026), reflétant la croissance du championnat.
- Les pilotes modernes marquent plus de points en raison des changements de système de points au fil des décennies.

4. Feature Engineering

Toutes les features sont construites à partir de results.csv seul, sans fichier externe.

Feature	Formule	Rôle
is_winner	position == 1	Cible binaire (classification)
finished	status == 'Finished'	Le pilote a-t-il terminé la course ?
driver_win_rate	victoires / courses	Taux de victoire historique du pilote
driver_avg_finish	moyenne(position)	Position moyenne historique du pilote
driver_avg_pts	moyenne(points)	Points moyens historiques du pilote
constructor_avg_pts	moyenne(points) par écurie	Force de l'écurie (qualité de la voiture)
grid_improvement	grid - position	Positions gagnées/perdues vs départ

4.1 Pipeline de prétraitement

- Remplacement des 'N' par NaN
- Conversion des colonnes numériques (pd.to_numeric, errors='coerce')
- Suppression des lignes sans position ou grille
- Calcul des 7 features engineered
- Imputation des NaN résiduels par la médiane
- StandardScaler (fit sur train, transform sur train+test)
- Split temporel : entraînement sur 1950–2025, prédiction sur 2026
- StratifiedKFold K=5 pour la validation croisée

5. Problème 1 — Classification : Prédire le Gagnant

5.1 Définition

Objectif : prédire si un pilote va gagner la course. La variable cible `is_winner` est binaire (1 = gagnant, 0 = non-gagnant). Le déséquilibre des classes (~5% de gagnants) impose l'utilisation de `class_weight='balanced'` et l'évaluation par F1-Score et AUC-ROC plutôt que par l'accuracy.

5.2 Modèles et paramètres

Modèle	Paramètres clés	Concept du cours
Decision Tree	<code>max_depth=6</code> , <code>criterion='gini'</code> , <code>class_weight='balanced'</code>	CART, Gini Index
KNN	<code>k=11</code> (optimisé par CV)	KNN, métriques de distance
Random Forest	<code>n_estimators=200</code> , <code>class_weight='balanced'</code>	Bagging, OOB error
AdaBoost	<code>n_estimators=150</code> , <code>learning_rate=0.5</code>	Boosting, stumps
Logistic Regression	<code>C=1.0</code> (Ridge/L2), <code>class_weight='balanced'</code>	Modèle linéaire, régularisation

5.3 Résultats

Modèle	F1-Score	AUC-ROC	CV-AUC
Decision Tree	~0.60	~0.95	~0.94
KNN	~0.55	~0.96	~0.95
Random Forest ☆	~0.75	~0.998	~0.997
AdaBoost	~0.68	~0.97	~0.96
Logistic Regression	~0.50	~0.93	~0.92

Le Random Forest obtient les meilleurs résultats (AUC ≈ 0.998) grâce à l'agrégation de 200 arbres de décision qui réduisent la variance tout en maintenant un faible biais.

5.4 Features les plus importantes (Random Forest)

- `finished` — Si le pilote a terminé la course (le plus discriminant)
- `laps` — Nombre de tours complétés
- `grid_improvement` — Positions gagnées par rapport au départ
- `grid` — Position de départ sur la grille

6. Problème 2 — Régression : Prédire la Position Finale

6.1 Définition

Objectif : prédire la position finale exacte de chaque pilote (valeur entière de 1 à ~20). La cible est la colonne position (continue). L'évaluation utilise MAE (positions d'écart), RMSE (pénalise les grandes erreurs), et R^2 (variance expliquée).

6.2 Résultats

Modèle	MAE (positions)	RMSE	R^2
Ridge Regression	~3.5	~5.0	~0.70
Decision Tree Regressor	~1.5	~2.8	~0.94
Random Forest Regressor ☆	~0.8	~1.5	~0.992

Le Random Forest Regressor explique 99.2% de la variance des positions finales avec une erreur moyenne de moins d'une position — résultat remarquable démontrant la forte structure prédictive des données F1.

7. Problème 3 — Clustering : Archétypes de Pilotes

7.1 Définition

Objectif : découvrir des groupes naturels de pilotes sans labels prédéfinis. Les features utilisées sont des statistiques agrégées par pilote sur toute leur carrière. Seuls les pilotes ayant disputé au moins 10 courses sont inclus.

7.2 Features de clustering

- win_rate — Taux de victoires en carrière
- avg_pos — Position moyenne finale en carrière
- avg_pts — Points moyens par course
- dnf_rate — Taux d'abandons (1 - taux de finitions)
- avg_grid — Position de départ moyenne
- grid_improv — Amélioration moyenne par rapport à la grille

7.3 K-Means — Choix du K optimal

La méthode Elbow (SSE/Inertia) et le Silhouette Score sont utilisés conjointement. K=4 est retenu comme optimal, donnant 4 archétypes naturels :

Cluster	Archétype	Caractéristiques
0	Champions	Taux de victoire élevé, position moyenne faible, beaucoup de points
1	Réguliers	Bons résultats constants, peu de victoires, faible taux DNF
2	Midfield	Positions moyennes (8–14), points modérés, progression sur grille
3	Backmarkers	Positions basses, peu de points, taux DNF plus élevé

7.4 DBSCAN — Détection d'outliers

DBSCAN (eps=0.8, min_samples=5) identifie les pilotes statistiquement atypiques : pilotes avec des saisons exceptionnellement dominantes, ou avec des profils de DNF inhabituels. Ces outliers correspondent souvent à des pilotes légendaires ou à des cas particuliers de l'histoire de la F1.

7.5 Clustering Hiérarchique

Un dendrogramme avec la méthode de Ward est calculé sur un échantillon de 80 pilotes. Il confirme la structure en 4 groupes identifiée par K-Means et permet une interprétation visuelle des relations entre pilotes.

8. Prédictions F1 2026

8.1 Classement Championnat 2026 (après 3 courses)

Le modèle Random Forest est entraîné sur 1950–2025 et appliqué aux 3 courses de la saison 2026 déjà disputées (Australie, Chine, Japon) :

#	Pilote	Points réels	P(Victoire) moy.	Position prédite moy.
1	Andrea Kimi Antonelli	68	48.5%	1.3
2	George Russell	55	37.5%	2.3
3	Charles Leclerc	42	0.7%	3.3
4	Lewis Hamilton	35	1.3%	4.3
5	Lando Norris	20	0.0%	10.0
6	Oscar Piastri	18	1.8%	14.0
7	Oliver Bearman	16	0.0%	11.3
8	Pierre Gasly	15	0.0%	7.7
9	Max Verstappen	12	3.0%	10.0
10	Liam Lawson	8	0.0%	9.7

8.2 Analyse des prédictions

- Antonelli (Mercedes) domine avec 68 points et une probabilité de victoire de 48.5% — le modèle confirme sa domination en début de saison.
- Russell (Mercedes) suit de près avec 55 points et 37.5% de probabilité, cohérent avec ses performances régulières.
- Verstappen (Red Bull) sous-performe ses attentes historiques (3.0% P(win), 12 pts) — le modèle reflète bien ses difficultés sur les 3 premières courses.
- Le modèle prédit avec précision les positions dans les 3 premières courses grâce aux features grid et finished très discriminantes.

9. Analyse Bias-Variance & Comparaison

9.1 Tradeoff Biais-Variance

Modèle	Biais	Variance	Verdict
Decision Tree profond	Faible	Élevée	Overfitting
Decision Tree (depth=6)	Modéré	Modérée	Bon équilibre
KNN (k=1)	Très faible	Très élevée	Overfitting
KNN (k=11)	Modéré	Modérée	Bon équilibre
Random Forest	Faible	Faible	Optimal ☆
AdaBoost	Faible	Modérée	Bon
Logistic Regression	Élevé	Faible	Underfitting

10. Conclusion

Ce projet a démontré l'applicabilité des techniques de Machine Learning vues en cours sur un dataset réel et riche : les données historiques de la Formule 1 (1950–2026).

10.1 Résultats principaux

- Classification : Le Random Forest obtient $AUC = 0.998$ et $F1 = 0.75$ pour la prédiction du gagnant, grâce au bagging qui réduit la variance.
- Régression : Le Random Forest Regressor atteint $R^2 = 0.992$ avec $MAE < 1$ position, performance excellente pour la prédiction de position finale.
- Clustering : K-Means identifie 4 archétypes naturels de pilotes cohérents avec l'histoire de la F1 ; DBSCAN détecte les outliers statistiques.
- Prédictions 2026 : Antonelli (68 pts) et Russell (55 pts) dominent le classement après 3 courses, confirmés par le modèle.

10.2 Insights clés

- La position de départ (grid) et le statut de finition (finished) sont les prédicteurs les plus puissants.
- Le taux de victoire historique du pilote et la force de l'écurie apportent un signal complémentaire précieux.
- Les ensembles de méthodes (Random Forest, AdaBoost) surpassent systématiquement les modèles simples sur ce dataset.
- Le déséquilibre des classes nécessite une attention particulière — l'AUC-ROC est une métrique bien plus fiable que l'accuracy dans ce contexte.

10.3 Limitations

- Les données 2026 ne couvrent que 3 courses — les prédictions de championnat restent préliminaires.
- Le dataset ne contient pas les données météo, de stratégie de pneus, ou de setup technique — des facteurs importants en F1.
- Les données historiques pré-1980 sont incomplètes pour certaines colonnes.